



中國人民大學
RENMIN UNIVERSITY OF CHINA



中国人民大学信息学院
SCHOOL OF INFORMATION RENMIN UNIVERSITY OF CHINA

新一代智能交互系统初探： 如何让大模型能听、能说、能看、能动手？

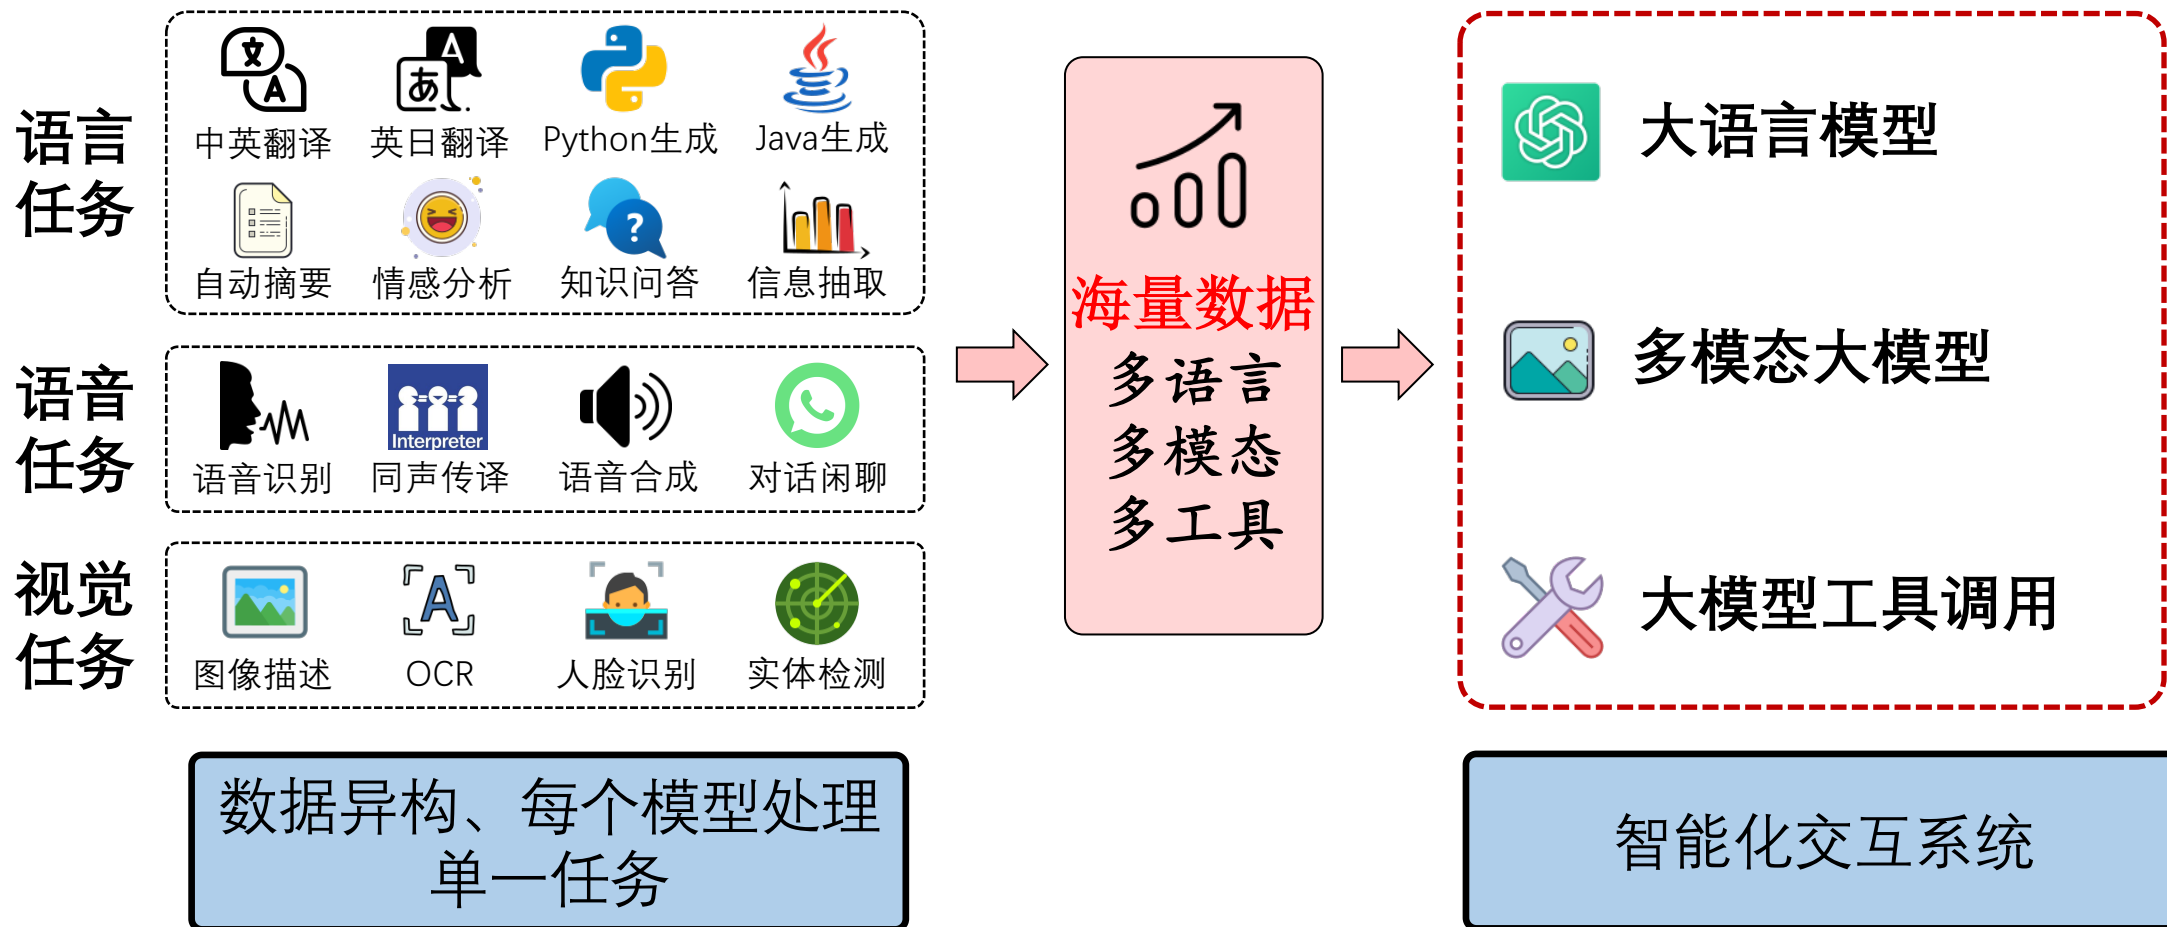
张绍磊

中国人民大学信息学院

美团

2025.09.23


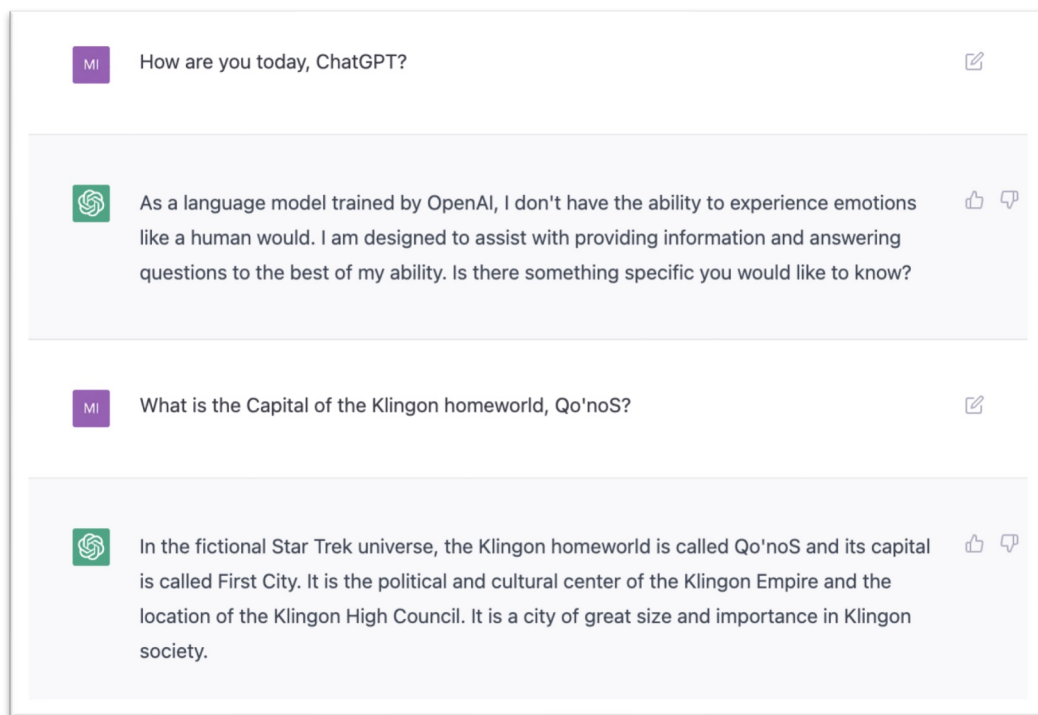
智能交互系统范式转变（2020-2025）




文本交互→更多交互模式

■ 智能化的发展推动交互模式的升级


如何让大模型能听、能说、能看、能动手？



大模型智能交互




大模型智能交互



“All in One” 实时语音模型


- StreamSpeech: 以端到端的**无缝方式**完成离线/任意延时下的语音识别、语音翻译、语音合成



Shaolei Zhang, et, al. StreamSpeech: Simultaneous Speech-to-Speech Translation with Multi-task Learning. ACL 2024.

StreamSpeech

- 流式语音编码器 + 实时文本解码器 + 同步语音合成模块
- CTC Decoder 通过辅助任务学习序列间的对齐



Shaolei Zhang, et, al. StreamSpeech: Simultaneous Speech-to-Speech Translation with Multi-task Learning. ACL 2024.

离线语音到语音翻译



- 超越当前最佳的UnitY (Meta)
- 推理平均加速4倍

StreamSpeech 推理加速比


Models	Fr→En		Es→En		De→En	
	ASR-BLEU	Speedup	ASR-BLEU	Speedup	ASR-BLEU	Speedup
UnitY	27.77	1.0×	24.95	1.0×	18.74	1.0×
StreamSpeech	28.45	3.6×	27.25	4.5×	20.93	4.5×

StreamSpeech 离线语音到语音翻译性能


Models	#Param.	Fr→En		Es→En		De→En		Average	
		greedy	beam10	greedy	beam10	greedy	beam10	greedy	beam10
Ground Truth	-	84.52		88.54		75.53		82.86	
S2UT	73M	20.91	22.23	16.94	18.53	2.46	2.99	13.44	14.58
Translatotron	79M	16.96	/	8.72	/	1.97	/	9.22	/
Translatotron 2	87M	25.49	26.07	22.35	22.93	16.24	16.91	21.36	21.97
DASpeech	93M	25.03	/	21.37	/	16.14	/	20.85	/
UnitY	67M	26.90	27.77	23.93	24.95	18.19	18.74	23.01	23.82
StreamSpeech	70M	27.58**	28.45**	26.16**	27.25**	19.72**	20.93**	24.49	25.54

实时语音到语音翻译


■ 滞后2s, 取得良好的翻译性能



(a) Fr→En



(b) Es→En



(c) De→En

Shaolei Zhang, et, al. StreamSpeech: Simultaneous Speech-to-Speech Translation with Multi-task Learning. ACL 2024.

StreamSpeech



- Web Demo: 实时语音到语音翻译，同步输出中间结果

首个一体化离线/流式语音模型
开源模型1200 stars



StreamSpeech GitHub

ACL 2024

StreamSpeech: Simultaneous Speech-to-Speech Translation with Multi-task Learning

Authors: Shaolei Zhang, Qingkai Fang, Shoutao Guo, Zhengrui Ma, Min Zhang, Yang Feng*

StreamSpeech is an "All in One" seamless model for offline and simultaneous speech recognition, speech translation and speech synthesis under any latency.

[arXiv 2406.03049](#) [Demo](#) [Listen to StreamSpeech](#) [StreamSpeech Models](#) [GitHub Repo](#) 286

Latency (ms) 320 未选择任何文件


Streaming Inputs

Streaming Speech Recognition

Simultaneous Speech-to-Text Translation


Simultaneous Speech-to-Speech Translation

大模型智能交互



视觉大模型


- LLaVA: 将视觉信息编码成若干视觉标记 (vision tokens), 输入至LLM上下文中, 实现视觉信息理解
- LLaVA-v1.5中, 一张图像需要576个token, 明显的计算开销



[1] Liu H, Li C, Wu Q, et al. Visual instruction tuning. NeurIPS 2023.

视觉大模型

- LLaVA: 将视觉信息编码成若干视觉标记 (vision tokens), 输入至LLM上下文中, 实现视觉信息理解
- LLaVA-v1.5中, 一张图像需要576个token, 明显的计算开销




[1] Liu H, Li C, Wu Q, et al. Visual instruction tuning. NeurIPS 2023.


高效视觉大模型

- 挑战：如何减少视觉标记数量，保留视觉理解能力？
- 观察：LLM对视觉标记的理解过程中，（1）首先将Vision Tokens中的视觉信息融合进指令标记，（2）然后基于融合了视觉信息的指令标记生成回复

回复对指令标记的关注



(a) LLaVA-v1.5-Vicuna-7B



(b) LLaVA-v1.5-Vicuna-13B


指令标记对视觉标记的关注

逐层注意力权重分析


高效视觉大模型

- 挑战：如何减少视觉标记数量，保留视觉理解能力？
- 观察：LLM对视觉标记的理解过程中，（1）首先将Vision Tokens中的视觉信息融合进指令标记，（2）然后基于融合了视觉信息的指令标记生成回复

前几层中，几乎全部视觉标记被关注



(a) LLaVA-v1.5-Vicuna-7B




(b) LLaVA-v1.5-Vicuna-13B

逐层注意力熵分析

高效视觉大模型

- 挑战：如何减少视觉标记数量，保留视觉理解能力？
- 观察：LLM对视觉标记的理解过程中，（1）首先将Vision Tokens中的视觉信息融合进指令标记，（2）然后基于融合了视觉信息的指令标记生成回复



直接减少输入到LLM
的视觉标记数必然
影响视觉能力

移除某些层的vision
tokens对视觉能力的影响

高效视觉大模型

- 挑战：如何减少视觉标记数量，保留视觉理解能力？
- 观察：LLM对视觉标记的理解过程中，（1）首先将Vision Tokens中的视觉信息融合进指令标记，（2）然后基于融合了视觉信息的指令标记生成回复

预先将视觉信息融入文本指令

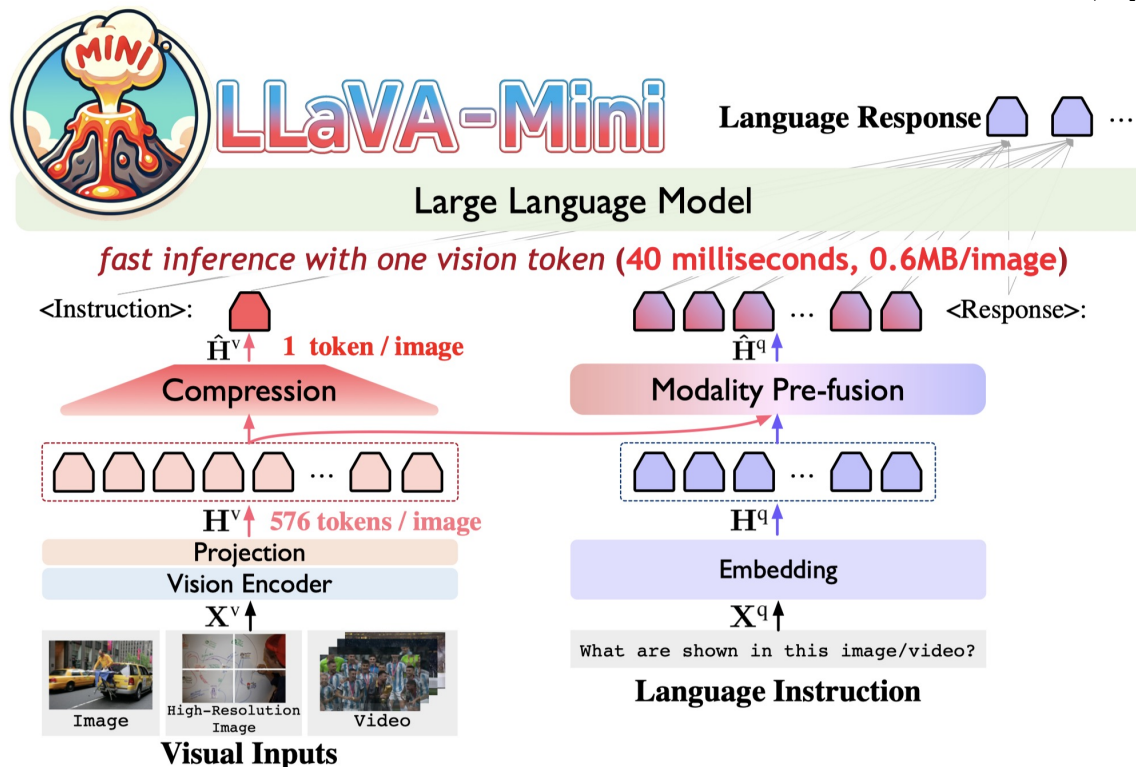


减少输入到LLM的视觉标记数


高效视觉大模型LLaVA-Mini

■ LLaVA-Mini


- **模态压缩**: 将视觉标记压缩为更少数量
- **模态预融合**: 将视觉信息融合进文本指令，确保视觉理解能力



(a) Compression



(b) Modality Pre-fusion




高效视觉大模型LLaVA-Mini

■ LLaVA-Mini

□ 模态压缩：将视觉标记动态压缩为更少数量

- 基于查询的压缩方法
- 引入 C^2 个可学习的query，和视觉标记序列交互，动态压缩视觉模态

(a) Compression



$$\hat{H}^V = A \cdot H^V,$$

$$\text{其中 } A = \text{Softmax} \left((Q^V + PE(Q^V)) \cdot (H^V + PE(H^V))^T \right)$$


LLM处理的视觉标记数：
 $N^2 \rightarrow C^2$

高效视觉大模型LLaVA-Mini

■ LLaVA-Mini

- **模态压缩**：将视觉标记动态压缩为更少数量
- **模态预融合**：将视觉信息融合进文本指令，确保视觉理解能力
 - 利用Transformer模块实现文本序列和视觉序列的融合

(b) Modality Pre-fusion

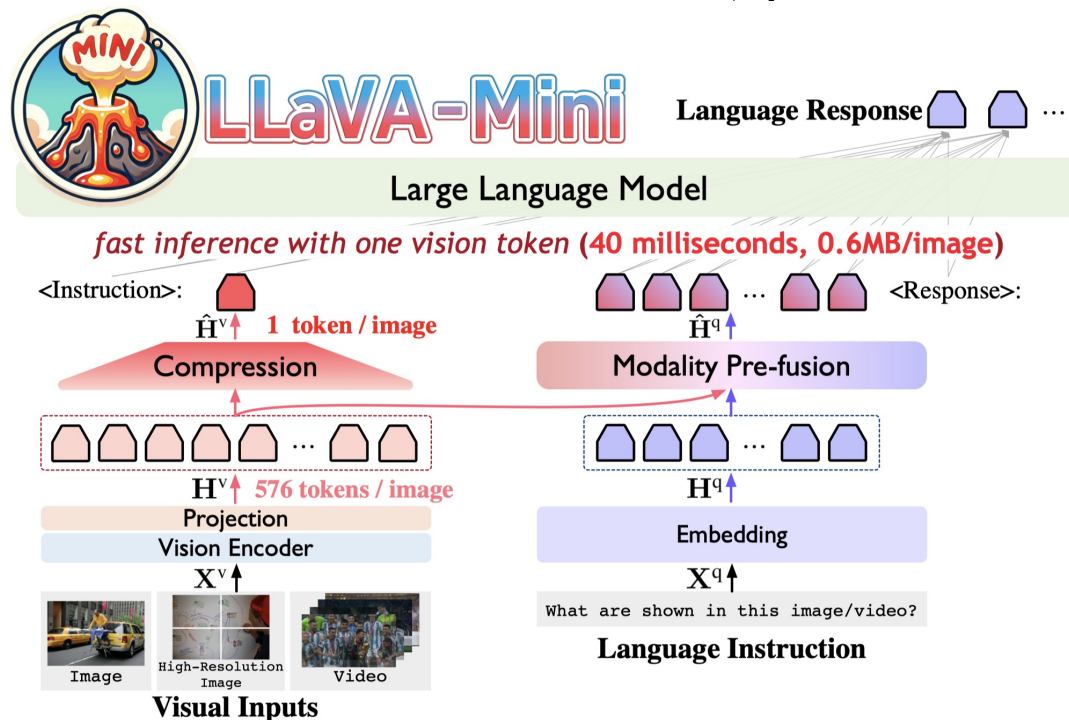


在LLM外部，将视觉模态和文本模态融合

高效视觉大模型LLaVA-Mini

■ LLaVA-Mini


- **模态压缩**：将视觉标记动态压缩为更少数量
- **模态预融合**：将视觉信息融合进文本指令，确保视觉理解能力




高分辨率图像：划分成多个子图

视频处理：按照1fps采样

(a) Compression



(b) Modality Pre-fusion



高效视觉大模型LLaVA-Mini

■ 图像理解能力

□ 压缩率0.17%，取得和LLaVA-v1.5相媲美的水平

Methods	LLM	Res.	#Vision Tokens	VQA ^{v2}	GQA	VisWiz	SciQA	VQA ^T	POPE	MME	MMB	SEED	LLaVA ^W	MM-Vet	Avg. (%)
BLIP-2	Vicuna-13B	224	32	65.0	41.0	19.6	61.0	42.5	85.3	1293.8	–	46.4	38.1	22.4	–
InstructBLIP	Vicuna-7B	224	32	–	49.2	34.5	60.5	50.1	–	–	36.0	53.4	60.9	26.2	–
IDEFICS-9B	LLaMA-7B	224	64	50.9	38.4	35.5	–	25.9	–	–	48.2	–	–	–	–
IDEFICS-80B	LLaMA-65B	224	64	60.0	45.2	36.0	–	30.9	–	–	54.5	–	–	–	–
Qwen-VL	Qwen-7B	448	256	78.8	59.3	35.2	67.1	63.8	–	–	38.2	56.3	–	–	–
Qwen-VL-Chat	Qwen-7B	448	256	78.2	57.5	38.9	68.2	61.5	–	1487.5	60.6	58.2	–	–	–
SPHINX	LLaMA-13B	224	289	78.1	62.6	39.9	69.3	51.6	80.7	1476.1	66.9	56.2	73.5	36.0	56.0
SPHINX-2k	LLaMA-13B	762	2890	80.7	63.1	44.9	70.6	61.2	87.2	1470.6	65.9	57.9	76.9	40.2	59.0
mPLUG-Owl2	LLaMA-7B	448	1024	79.4	56.1	54.5	68.7	54.3	–	1450.2	64.5	57.8	–	36.2	–
Video-LLaVA	Vicuna-7B	224	256	74.7	60.3	48.1	66.4	51.8	84.4	–	60.9	–	73.1	32.0	–
LLaVA-v1.5	Vicuna-7B	336	576	78.5	62.0	50.0	66.8	58.2	85.9	1510.7	64.3	58.6	63.4	30.5	56.3
LMs with fewer vision tokens															
MQT-LLaVA	Vicuna-7B	336	2	61.0	50.8	48.5	65.0	–	74.5	1144.0	54.4	–	41.7	19.5	–
MQT-LLaVA	Vicuna-7B	336	36	73.7	58.8	51.0	66.8	–	81.9	1416.3	63.4	–	59.6	27.8	–
MQT-LLaVA	Vicuna-7B	336	256	76.8	61.6	53.1	67.6	–	84.4	1434.5	64.3	–	64.6	29.8	–
PruMerge	Vicuna-7B	336	32	72.0	–	–	68.5	56.0	76.3	1350.3	60.9	–	–	–	–
PruMerge++	Vicuna-7B	336	144	76.8	–	–	68.3	57.1	84.0	1462.4	64.9	–	–	–	–
LLaMA-VID	Vicuna-7B	336	2	–	55.5	–	68.8	49.0	83.1	–	–	–	–	–	–
VoCo-LLaMA	Vicuna-7B	336	1	72.3	57.0	–	65.4	–	81.4	1323.3	58.8	53.7	–	–	–
TokenPacker	Vicuna-7B	336	36	75.0	59.6	50.2	–	–	86.2	–	62.8	–	–	29.6	–
Ours															
LLaVA-Mini	Vicuna-7B	336	1	77.6	60.9	56.2	70.4	57.0	84.4	1466.0	65.6	58.5	68.9	36.6	57.9
Δ compare to LLaVA-v1.5			0.17%	-0.9	-1.1	+6.1	+3.6	-1.3	-1.5	-44.7	+1.3	-0.1	+5.5	+6.1	+1.6
LLaVA-Mini-HD	Vicuna-7B	672	64	78.9	61.8	58.5	69.7	59.1	85.3	1476.8	67.5	60.2	69.3	33.9	58.6
Δ compare to LLaVA-v1.5			11.1%	+0.4	-0.2	+8.5	+2.9	+0.9	-0.6	-33.9	+3.2	+1.6	+5.9	+3.4	+2.4
LLaVA-Mini* (Image & Video)	LLaMA-3.1-8B-Instruct	336	1	79.0	61.3	57.4	83.1	58.5	85.3	1522.7	71.6	63.0	70.2	37.2	60.7

在模态压缩时，
确保了视觉理解能力

高效视觉大模型LLaVA-Mini

■ 视频理解能力

- 在视频问答、基于视频的生成均表现良好
- 1fps采样，每张图像1个视觉标记

Methods	#Frames	#Vision Tokens per Frame	Video-based Question-Answer						Video-based Generative Performance					
			MSVD-QA		MSRVTT-QA		ActivityNet-QA		Correctness	Detail	Contextual	Temporal	Consistency	Avg.
			Acc.	Score	Acc.	Score	Acc.	Score						
LLaMA Adapter	5	256	54.9	3.1	43.8	2.7	34.2	2.7	2.03	2.32	2.30	1.98	2.15	2.19
VideoChat	16	32	56.3	2.8	45.0	2.5	26.5	2.2	2.23	2.50	2.53	1.94	2.24	2.30
Video-LLaMA	16	64	51.6	2.5	29.6	1.8	12.4	1.1	1.96	2.18	2.16	1.82	1.79	1.99
Video-ChatGPT	100	~3.6	64.9	3.3	49.3	2.8	35.2	2.7	2.40	2.52	2.62	1.98	2.37	2.37
BT-Adapter	100	~2.6	67.5	3.7	57.0	3.2	45.7	3.2	2.68	2.69	3.27	2.34	2.46	2.69
MovieChat	2048	32	75.2	3.8	52.7	2.6	45.7	<u>3.4</u>	2.76	2.93	3.01	2.24	2.42	2.65
LLaMA-VID	1fps	2	69.7	3.7	57.7	3.2	<u>47.4</u>	3.3	<u>2.96</u>	3.00	<u>3.53</u>	<u>2.46</u>	<u>2.51</u>	<u>2.88</u>
Video-LLaVA	8	256	70.7	<u>3.9</u>	<u>59.2</u>	<u>3.5</u>	45.3	3.3	2.87	2.94	3.44	2.45	<u>2.51</u>	2.84
LLaVA-Mini	1fps	1	<u>70.9</u>	4.0	59.5	3.6	53.5	3.5	2.97	<u>2.99</u>	3.61	2.48	2.67	2.94

高效视觉大模型LLaVA-Mini

■ 长视频理解能力

- 在推理阶段能够适应更长的视频输入序列

视频平均长度11分钟，最长长度143分钟

Methods	#Frames	Holistic		Single Detail			Multi Detail		Avg.
		TR	AR	NQA	ER	PQA	AO	AC	
Avg. Video Duration (minute)		7	10	14	10	8	16	13	11
Max Video Duration (minute)		20	543	139	20	13	137	130	143
Video-ChatGPT	100	26.9	24.0	40.3	42.0	29.9	25.1	31.1	31.3
MovieChat	2048	29.5	25.0	24.2	24.7	25.8	28.6	22.8	25.8
Movie-LLM	1fps	30.0	29.0	29.6	24.7	24.1	20.5	24.8	26.1
TimeChat	96	23.1	27.0	24.5	28.4	25.8	24.7	32.0	30.9
LLaMA-VID	1fps	50.8	34.5	30.1	32.7	32.5	23.9	27.8	33.2
MA-LMM	1000	51.9	35.5	43.1	38.9	35.8	25.1	24.3	36.4
LLaVA-Mini	1fps	76.0	50.0	44.5	37.5	49.0	24.3	18.4	42.8

表：长视频基准MLVU结果

3分钟第一人称视频

Methods	#Frames	EgoSchema
Random	-	20
mPLUG-Owl	16	31.1
InternVideo	16	32.1
Video-ChatGPT	100	36.2
VideoChat	16	42.2
TimeChat	96	33.0
LLaMA-VID	1fps	38.5
Video-LLaVA	8	38.4
LLaVA-Mini	1fps	51.2


表：长视频基准EgoSchema结果

高效视觉大模型LLaVA-Mini


效率分析

- 计算量：节省 77% FLOPs
- 推理延时：113毫秒 $\Rightarrow$ 38毫秒

实现快速响应



(a) 图像理解的计算量和延时




(b) 高分辨图像理解的计算量和延时

高效视觉大模型LLaVA-Mini

■ 效率分析

□ 显存占用：358MB/图像 $\Rightarrow$ 0.6MB/图像



支持10000帧（3小时）
长视频处理

图：处理不同长度
视频的显存占用


高效视觉大模型LLaVA-Mini

■ 模态压缩的有效性

- 基于查询的压缩方法能有效提取图像中的关键特征

有效感知图像细节

Image:



Instruction:
How much is Ray-Ban Meta Wayfarer?

LLaVA-Mini: The Ray-Ban Meta Wayfarer is priced at \$299 USD.

Latency: 38ms, Vision token: 1


GPT-4o: The price of the Ray-Ban Meta Wayfarer sunglasses shown in the image is \$299.00.

Video-LLaVA: The price of the Ray-Ban Meta Wayfarer is \$129.99.

Latency: 80ms, Vision tokens: 256

LLaVA-v1.5: The Ray-Ban Meta Wayfarer is priced at \$199.

Latency: 110ms, Vision tokens: 576



图：模态压缩可视化

高效视觉大模型LLaVA-Mini

■ Demo



Code

llava-mini

Image


将图像拖放到此处
- 或 -
点击上传



Video


将视频拖放到此处
- 或 -
点击上传



Parameters

Temperature

0

0 1

Top P

0.7

0 1

Max output tokens

512

0 1024

LLaVA-Mini Chatbot

Enter text and press ENTER

Send

Upvote

Downvote

Flag

Regenerate

Clear

Image Examples



这幅图像有何不寻常之处?



What's the text on the cake?

Video Examples



描述这个视频?




What happened in this video?

中国人民大学信息学院 张绍磊

新一代智能交互系统初探：如何让大模型能听、能说能看、能动手？ 28

大模型智能交互



听/说



StreamSpeech: Simultaneous Speech-to-Speech Translation with Multi-task Learning

看



LLaVA-Mini: Efficient Image and Video Large Multimodal Model with One Vision Token

听/说/看



Stream-Omni: Simultaneous Multimodal Interactions with Large Language-Vision-Speech Model

工具




DeepAnalyze: Agentic Data Science over Structural Data

多模态大模型架构

■ 多模态大模型

- 视觉大模型：基于视觉信息进行文本交互
- 代表性工作：LLaVA、LLaVA-NeXT、Qwen-VL


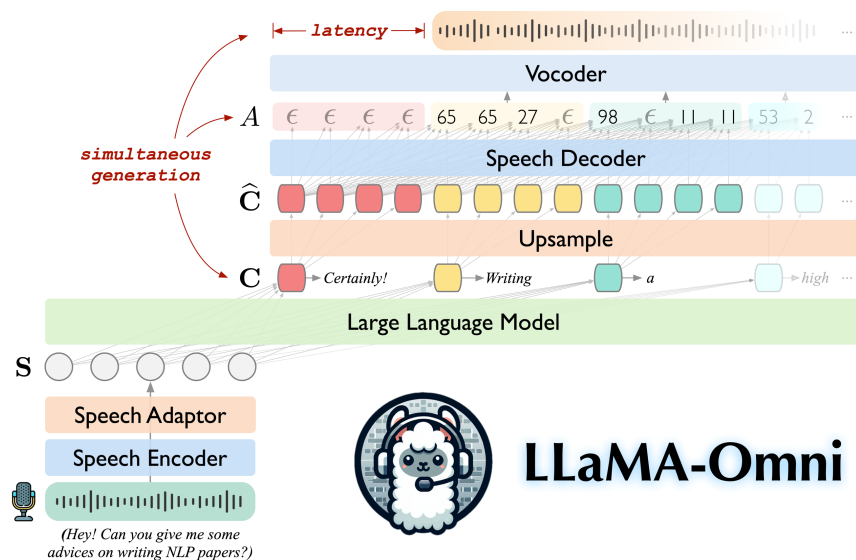


常见架构：视觉编码器 + 大语言模型

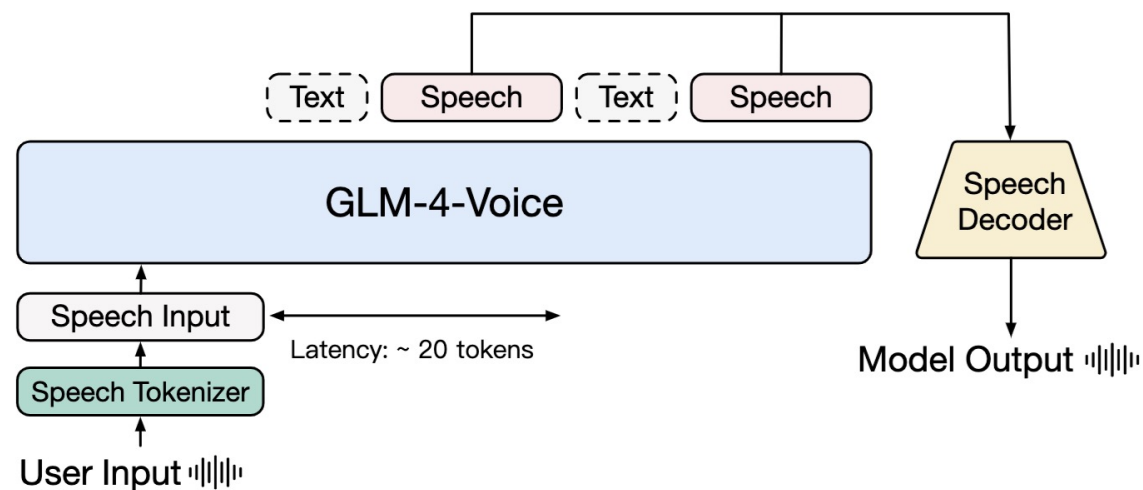
多模态大模型架构

■ 多模态大模型

- 语音大模型：语音交互
- 代表性工作：LLaMA-Omni、GLM-4-Voice



LLaMA-Omni





常见架构：语音编码器/语音Tokenizer + 大语言模型

多模态大模型架构

■ 多模态大模型


- 三模态大模型：基于视觉信息的语音交互
- 代表性工作：VITA-1.5、Qwen2.5-Omni



常见架构：语音编码器 + 视觉编码器 + 大语言模型

多模态大模型架构局限性


- 现有方案序列维度拼接，以数据驱动方式建模模态对齐




依赖大量三模态数据
中间文本不可见

多模态大模型架构局限性

- 现有方案序列维度拼接，以数据驱动方式建模模态对齐
- 解决方案：以文本为中心，更有针对性地建模模态对齐



依赖大量三模态数据
中间文本不可见



视觉（和文本语义互补）：序列维度拼接
语音（和文本语义一致）：层维度映射


基于高效模态对齐的三模态大模型

■ Stream-Omni:

- 基于视觉输入，进行语音交互，同时提供中间文本结果

■ 主要模块:

- 大语言模型
- 视觉编码器
- 底部/顶部语音层




基于高效模态对齐的三模态大模型

■ 视觉-文本对齐:

- 沿用LLaVA架构的基于序列维度拼接的建模方式

利用视觉编码器提取视觉表示，融入文本LLM的上下文中。




基于高效模态对齐的三模态大模型

- 语音-文本对齐：
 - 离散化表示
 - 层之间建模语音文本映射


模型总共40层：

- 底部语音层（1-3层）通过CTC将语音映射到文本；
- 文本LLM（4-35层），生成回复；
- 顶部语音层（36-40层）将生成的文本映射到语音；



基于高效模态对齐的三模态大模型

通过层维度映射建模语音-文本对齐的优势：



(1) 高效性：通过映射将 LLM 的文本能力迁移到语音模态，避免大规模语音预训练。

(2) 灵活性：在语音交互过程中，可以同时呈现中间文本结果

多模态能力

■ 视觉理解能力

□ 性能和现有视觉大模型相当

Methods	LLM	VQA ^{v2}	GQA	Vis Wiz	Sci QA	VQA ^T	POPE	MME	MMB	SEED	LLaVA ^w	MM- Vet	Avg. (%)
BLIP-2	Vicuna-13B	65.0	41.0	19.6	61.0	42.5	85.3	1293.8	—	46.4	38.1	22.4	-
InstructBLIP	Vicuna-7B	—	49.2	34.5	60.5	50.1	—	—	36.0	53.4	60.9	26.2	—
IDEFICS-9B	LLaMA-7B	50.9	38.4	35.5	—	25.9	—	—	48.2	—	—	—	—
Qwen-VL	Qwen-7B	78.8	59.3	35.2	67.1	63.8	—	—	38.2	56.3	—	—	—
Qwen-VL-Chat	Qwen-7B	78.2	57.5	38.9	68.2	61.5	—	1487.5	60.6	58.2	—	—	-
SPHINX	LLaMA-13B	78.1	62.6	39.9	69.3	51.6	80.7	1476.1	66.9	56.2	73.5	36.0	56.0
SPHINX-2k	LLaMA-13B	80.7	63.1	44.9	70.6	61.2	87.2	1470.6	65.9	57.9	76.9	40.2	59.0
mPLUG-Owl2	LLaMA-7B	79.4	56.1	54.5	68.7	54.3	-	1450.2	64.5	57.8	-	36.2	-
LLaVA-1.5	Vicuna-7B	78.5	62.0	50.0	66.8	58.2	85.9	1510.7	64.3	58.6	63.4	30.5	56.3
LLaVA-NeXT	Vicuna-7B	81.8	64.2	57.6	70.1	64.9	86.53	1519	67.4	70.2	81.6	43.9	62.6
LLaVA-OV	Qwen2-7B	-	-	-	96.0	-	-	1580	80.8	75.4	-	-	-
VITA-1.5	Qwen2-7B	78.8	60.6	54.8	90.9	65.0	85.7	1687.7	76.7	70.4	71.0	49.6	64.0
Stream-Omni	LLaMA-3.1-8B	79.7	68.3	45.5	93.4	62.7	86.0	1752.7	82.4	76.3	71.2	44.7	64.7

多模态能力

■ 语音交互能力

- 基于知识的语音交互评估 Llama Question、Web Question

通过更少语音数据，将LLM知识/能力迁移到语音模态

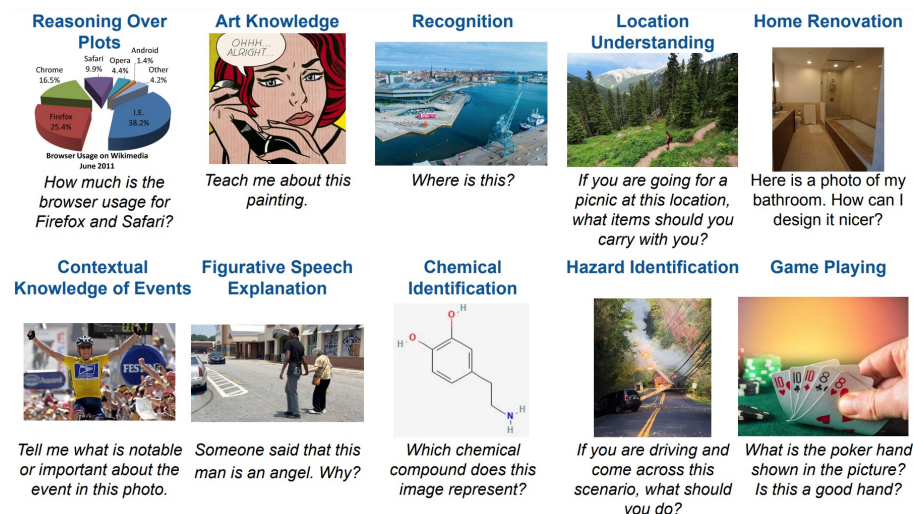
Methods	Llama Q.		Web Q.		Avg.	
	S-T	S-S	S-T	S-S	S-T	S-S
TWIST	-	4.0	-	1.5	-	2.8
SpeechGPT	21.6	-	6.5	-	14.1	-
Spectron	21.9	-	6.1	-	14.0	-
Moshi	62.3	21.0	26.6	9.2	44.5	15.1
GLM-4-Voice	64.7	<u>50.7</u>	32.2	15.9	48.5	33.3
Freeze-Omni	72.0	-	44.7	-	58.4	-
LLaMA-Omni	67.7	49.0	33.4	<u>23.7</u>	50.6	<u>36.4</u>
VITA-1.5	76.7	-	42.7	-	<u>59.7</u>	-
Stream-Omni	<u>76.3</u>	65.0	<u>44.2</u>	27.5	60.3	46.3

S-T: 语音到文本评估; S-S: 语音到语音评估

多模态能力

■ 基于视觉的语音交互能力

□ 构建了真实世界的视觉-语音交互评估集SpokenVisIT



VisIT-Bench^[1]

Methods	SpokenVisIT		
	V+T→T	V+S→T	V+S→S
GPT-4V	4.81	-	-
VITA-1.5	3.63	3.45	-
Stream-Omni	3.93	3.68	2.62

V+T→T: 基于视觉的文本到文本评估

V+S→T: 基于视觉的语音到文本评估

V+S→S: 基于视觉的语音到语音评估


[1] Yonatan Bitton, et.al. VisIT-Bench: A Benchmark for Vision-Language Instruction Following Inspired by Real-World Use. NeurIPS 2023.

多模态能力




■ 基于视觉的语音交互能力

同步呈现中间
文本结果



大模型智能交互

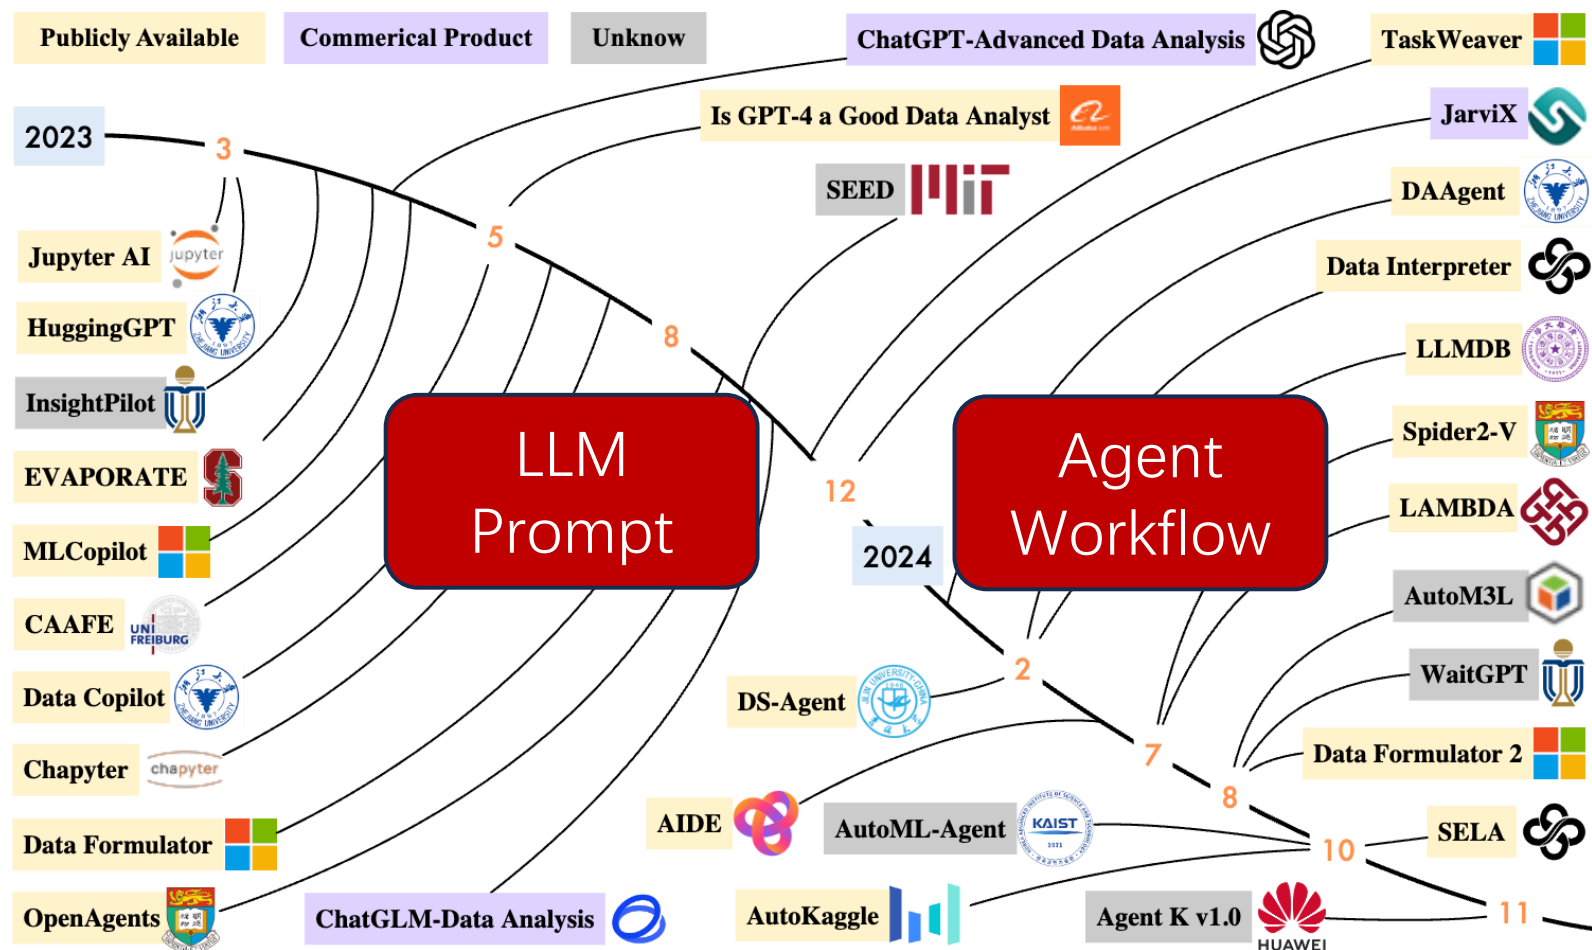


大模型工具调用

- 大模型推理
 - 数学、代码、问答...
- DeepSearch/DeepResearch
 - Agentic检索，完成复杂任务
- 结构化数据如何处理？
 - 能否自动化处理数据库、各类型文件？
 - LLM for Data Science

大模型工具调用


■ LLM for Data Science



图源: A Survey on Large Language Model-based Agents for Statistics and Data Science

大模型工具调用

- LLM for Data Science
- 自动和环境交互



“在真实环境中训练Agentic model优于基于Prompt的Agent系统”

—— ChatGPT Agent、GLM 4.5等最新模型


“小规模LLM更适合构建Agentic AI”

—— Small Language Models are the Future of Agentic AI

DeepAnalyze



■ 模拟数据科学家完成全流程数据科学任务



■ Data Scientist是如何处理复杂数据科学任务的？



能胜任开放域下数据科学任务：

1. 分析任务，并规划步骤
2. 在环境中读取数据
3. 观察并理解数据
4. 通过代码完成数据分析、建模、可视化...重复直到完成任务
5. 总结、呈现结果

■ Data Scientist是如何处理复杂数据科学任务的？



能胜任开放域下数据科学任务：

1. 分析任务，并规划步骤
2. 在环境中读取数据
3. 观察并理解数据
4. 通过代码完成数据分析、建模、可视化...重复直到完成任务
5. 总结、呈现结果

利用 Agentic AI 模拟数据科学家行为 ⇒ 在开放域下胜任数据科学全流程

DeepAnalyze

- 引入若干action，与环境、数据交互

数据科学家

完成数据科学任务的步骤：

1. 分析任务，并规划步骤
2. 在环境中读取数据
3. 观察并理解数据
4. 通过代码完成数据分析、建模、可视化...重复直到完成任务
5. 总结、呈现结果

DeepAnalyze

<Analyze>

<Code>&<Execute>

<Understand>

自动执行各action

<Answer>

Data:



Instruction:

Give me a comprehensive data analysis report based on these files.
Requirements: (1)...(2)...

Response:

<Analyze>

To complete this task, I need to (1) load the data, (2) observe its structure, (3) select a statistical model, ... (8) finally generate an analysis report. Next, I will first look at the data.

</Analyze>

<Code>

```
python
import pandas as pd
df = pd.read_csv('data.csv')
print("=== First 5 Rows ===\n", df.head()) ...
```

</Code>

<Execute>

```
=== First 5 Rows ===
Name Age Salary Department
Bob 23 6,000 Marketing ...
```

</Execute>

<Understand>

Through the execution results, I know the csv file is about ..., it has 4 columns...

</Understand>

<Analyze>...<Understand>...<Code><Execute>...

<Answer>

Analysis Report of Data:...

</Answer>

Intermediate Results



Processed Data



Statistical Analysis



Data Insight



Visualization



Data Modeling

Real-world Environment

DeepAnalyze

- 引入若干action，与环境、数据交互

数据科学家

完成数据科学任务的步骤：

1. 分析任务，并规划步骤
2. 在环境中读取数据
3. 建模、可视化...等交互
4. 到完成任务
5. 总结、呈现结果

DeepAnalyze

<Analyze>

<Code>&<Execute>

自动执行各action

<Answer>

Data:



Instruction:

Give me a comprehensive data analysis report based on these files.
Requirements: (1)...(2)...

Response:

<Analyze>

To complete this task, I need to (1) load the data, (2) observe its structure, (3) select a statistical model, ... (8) finally generate an analysis report. Next, I will first look at the data.

</Analyze>

<Code>

```
python
import pandas as pd
```

Intermediate Results



Processed Data



Analysis

ght

Visualization



Data Modeling

通过action定义，DeepAnalyze能模仿数据科学家与数据交互



如何学习数据科学思维、流程、能力？

Real-world Environment

DeepAnalyze



Curriculum Agentic Post-training


模拟人类从易到难的学习过程

阶段1：初学者→从业者

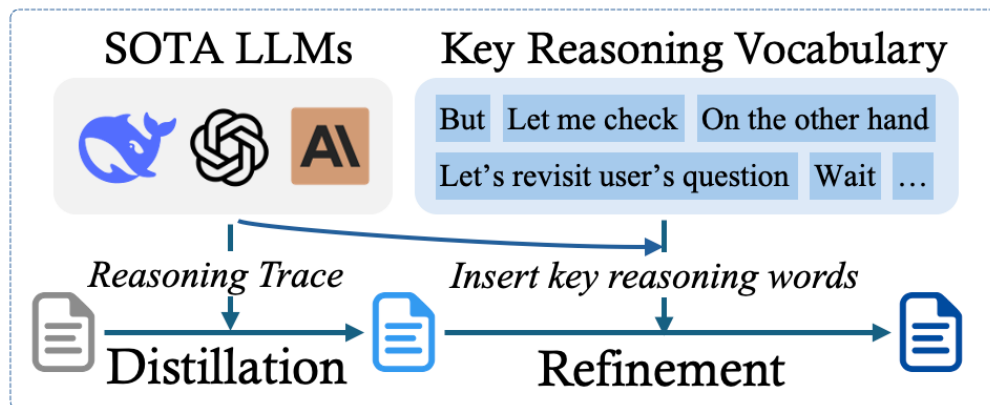
- 学习推理、结构化数据理解、代码等单一能力

阶段2：从业者→科学家


- 学习多能力的复杂数据任务
- 在真实环境中，自我进化



■ 数据工程



推理强化的数据增强




多智能体的Agentic数据合成

DeepAnalyze



- DeepAnalyze-8B在结构化数据理解、数据科学等任务上媲美GPT-4o、Claude等闭源模型



**Agentic 训练方式
使得8B模型取得良
好表现**


DeepAnalyze



(半) 结构化数据上的
深度研究



大模型智能交互：多模态+Agentic交互



谢谢大家



联系方式



更多研究介绍

张绍磊

中国人民大学

zhangshaolei98@ruc.edu.cn

<https://zhangshaolei1998.github.io/>